

Análise Regressão Logística Binomial A2 - 2010-2016

Bibliotecas

Bancos

Juntando os bancos de cada período para as modelagens dos períodos.

A precipitação total no outono (“precip_tot_Autumn”) não demonstrou uma relação significativa com a transmissão da dengue (p-valor = 0,214), o que sugere que não há evidências suficientes para incluí-la no modelo, levando à sua remoção da análise.

```
#Lendo
banco_determinantes <- read_csv2("banco_determinantes_bi.csv")
clima_org_model_10_16_season <- read_csv("clima_org_model_10_16_season.csv")

#Excluido as variáveis que não serão utilizadas

banco_determinantes <- banco_determinantes[,!(names(banco_determinantes) %in%
      c("...1", "dengue_pattern_17_22"))]

clima_org_model_10_16_season <- clima_org_model_10_16_season[,!(names(clima_org_model_10_16_season) %in%
      c("...1", "dengue_pattern", "precip_tot_Autumn"))]

# Renomeia a nova primeira coluna
colnames(clima_org_model_10_16_season)[1] <- "muni_code"

# Juntando
det_10_16 <- full_join(banco_determinantes, clima_org_model_10_16_season , by = "muni_code")
det_10_16 <- det_10_16[, !names(det_10_16) %in% c("pop22")]

## Removendo os bancos para a análise ficar mais leve
```

```
remove(banco_determinantes)
remove(clima_org_model_10_16_season)
```

Análise 2010-2016

Análise do período de 2010-2016, primeira parte de uma série temporal da classificação de padrões de transmissão de todos os municípios brasileiros para dengue.

1. Arrumando variáveis

```
# Converter variáveis numéricas com vírgula decimal e categorizar as variáveis de texto
det_10_16 <- det_10_16 %>%
  mutate(
    across(where(~ all(grepl("[0-9,.]+$", .))), ~ as.numeric(gsub(",", ".", ".", .))),
    across(where(is.character), as.factor))

det_10_16$dengue_pattern_10_16 <- as.factor(det_10_16$dengue_pattern_10_16)

# Visão geral dos dados
summary(det_10_16)
```

muni_code	region	tipo_regiao	altitude
Min. :1100015	Min. :1.000	metropolitana : 445	Min. : 1.67
1st Qu.:2512126	1st Qu.:2.000	nao metropolitana:5125	1st Qu.: 222.60
Median :3146280	Median :3.000		Median : 427.60
Mean :3253591	Mean :2.898		Mean : 451.24
3rd Qu.:4119190	3rd Qu.:4.000		3rd Qu.: 650.83
Max. :5300108	Max. :5.000		Max. :1601.42

koppen	pop10	prop_residuo	prop_esgot
Aw :1337	Min. : 805	Min. : 0.00	Min. : 0.00
Cfa :1138	1st Qu.: 5235	1st Qu.: 54.33	1st Qu.: 12.85
As : 892	Median : 10934	Median : 74.08	Median : 38.03
BSh : 420	Mean : 34278	Mean : 70.21	Mean : 42.27
Cwa : 407	3rd Qu.: 23424	3rd Qu.: 89.22	3rd Qu.: 70.44
Cfb : 405	Max. :11253503	Max. :100.00	Max. :100.00
(Other): 971	NA's :5		
	bioma	dengue_pattern_10_16	temp_med_Autumn
			umid_med_Autumn

Amazonia	: 503	0:4915	Min.	:12.90	Min.	:52.73
Caatinga	:1095	1: 655	1st Qu.:	19.37	1st Qu.:	72.58
Cerrado	:1062		Median	:22.72	Median	:77.93
Mata Atlantica:	2741		Mean	:22.25	Mean	:76.60
Pampa	: 160		3rd Qu.:	25.36	3rd Qu.:	81.53
Pantanal	: 9		Max.	:28.18	Max.	:91.90
			NA's	:3	NA's	:3

thr_temp_Autumn	thr_umid_Autumn	thr_prec_Autumn	thr_temp_umid_Autumn
Min. : 0.00	Min. : 0.00	Min. : 0.00	Min. : 0.00
1st Qu.:38.57	1st Qu.:81.86	1st Qu.:18.00	1st Qu.:35.29
Median :84.43	Median :90.57	Median :23.43	Median :61.71
Mean :66.88	Mean :83.54	Mean :26.76	Mean :58.77
3rd Qu.:92.00	3rd Qu.:91.86	3rd Qu.:31.71	3rd Qu.:86.00
Max. :92.00	Max. :92.00	Max. :88.57	Max. :92.00

temp_med_Spring	umid_med_Spring	precip_tot_Spring	thr_temp_Spring
Min. :15.39	Min. :42.80	Min. : 0.0	Min. : 0.00
1st Qu.:21.58	1st Qu.:67.09	1st Qu.: 700.2	1st Qu.:68.14
Median :24.37	Median :71.88	Median :1667.6	Median :89.14
Mean :24.06	Mean :70.76	Mean :1443.3	Mean :77.53
3rd Qu.:26.29	3rd Qu.:76.70	3rd Qu.:2005.4	3rd Qu.:90.71
Max. :31.28	Max. :90.22	Max. :3257.9	Max. :90.71
NA's :3	NA's :3		

thr_umid_Spring	thr_prec_Spring	thr_temp_umid_Spring	temp_med_Summer
Min. : 0.00	Min. : 0.00	Min. : 0.00	Min. :18.47
1st Qu.:64.29	1st Qu.:17.14	1st Qu.:46.14	1st Qu.:23.49
Median :79.50	Median :34.29	Median :62.57	Median :24.94
Mean :71.55	Mean :30.18	Mean :59.01	Mean :24.67
3rd Qu.:89.14	3rd Qu.:40.57	3rd Qu.:74.14	3rd Qu.:25.94
Max. :90.71	Max. :78.43	Max. :90.71	Max. :28.77
			NA's :3

umid_med_Summer	precip_tot_Summer	thr_temp_Summer	thr_umid_Summer
Min. :55.31	Min. : 0	Min. : 0.00	Min. : 0.00
1st Qu.:74.01	1st Qu.:1234	1st Qu.:88.43	1st Qu.:83.14
Median :77.75	Median :1861	Median :90.29	Median :87.43
Mean :76.77	Mean :1884	Mean :87.28	Mean :82.16
3rd Qu.:80.86	3rd Qu.:2400	3rd Qu.:90.29	3rd Qu.:90.14
Max. :91.60	Max. :5920	Max. :90.29	Max. :90.29
NA's :3			

thr_prec_Summer	thr_temp_umid_Summer	temp_med_Winter	umid_med_Winter
Min. : 0.00	Min. : 0.00	Min. :11.43	Min. :36.38
1st Qu.:27.57	1st Qu.:75.57	1st Qu.:18.17	1st Qu.:56.63
Median :42.14	Median :84.57	Median :21.63	Median :69.07

```

Mean      :41.55   Mean      :79.21           Mean      :21.50   Mean      :66.70
3rd Qu.   :52.57   3rd Qu.   :89.86           3rd Qu.   :24.94   3rd Qu.   :77.93
Max.      :88.86   Max.      :90.29           Max.      :30.04   Max.      :90.85
                        NA's      :3           NA's      :3

precip_tot_Winter thr_temp_Winter thr_umid_Winter thr_prec_Winter
Min.      : 0.0    Min.      : 0.00   Min.      : 0.00   Min.      : 0.000
1st Qu.   :149.8   1st Qu.   :21.46   1st Qu.   :33.29   1st Qu.   : 2.714
Median    :396.7   Median    :74.50   Median    :75.57   Median    : 9.143
Mean      :669.6   Mean      :59.09   Mean      :61.54   Mean      :13.717
3rd Qu.   :1020.8  3rd Qu.   :92.00   3rd Qu.   :90.43   3rd Qu.   :23.429
Max.      :3122.8  Max.      :92.00   Max.      :92.00   Max.      :82.571

thr_temp_umid_Winter
Min.      : 0.00
1st Qu.   : 7.00
Median    :16.71
Mean      :31.09
3rd Qu.   :49.43
Max.      :92.00

```

2. Verificação dos pressupostos

1. Verificação de valores ausentes (NA)

Valores ausentes podem comprometer a análise, pois a regressão binomial não lida bem com dados incompletos. Se houver muitas ausências em uma variável, pode ser necessário removê-la ou imputar valores. Caso haja poucos valores faltantes, a remoção de linhas (`na.omit()`) pode ser suficiente. A ausência de NA indica que o banco está pronto para a modelagem.

Interpretação: Foram retiradas 8 linhas ou seja 8 municípios, são eles: xxxxxxxx

2. Análise de multicolinearidade com VIF

A multicolinearidade ocorre quando variáveis independentes estão altamente correlacionadas, dificultando a interpretação do modelo. O **VIF (Variance Inflation Factor)** mede essa relação: valores acima de 5 indicam uma correlação preocupante, e acima de 10 exigem ajustes, como exclusão ou transformação de variáveis.

Interpretação: Nenhum está acima de 10, então não precisa de ajuste, porém tem multicolinearidade moderada por que está de 5 a 10, mas isso o modelo pode dar conta no ajuste.

3. Verificação de outliers nos resíduos padronizados

Outliers podem distorcer os coeficientes da regressão binomial e afetar a qualidade da predição. A análise dos resíduos padronizados permite identificar observações extremas, geralmente consideradas problemáticas quando estão fora do intervalo de -3 a 3. Se houver muitos outliers, pode ser necessário revisar a entrada de dados ou aplicar transformações.

Interpretação: Foram retiradas 12 linhas ou seja 12 municípios com 8 de categoria 0 e 4 de categoria 1. Todos com intervalos acima de -3 e 3. Presentes na tabela outliers_binomial_model_10_16.csv.

```
# 1. Verificação de valores ausentes
cat("Valores ausentes por variável:\n")
```

Valores ausentes por variável:

```
#print(colSums(is.na(det_10_16)))

# Remover linhas com NA (se necessário)
det_10_16 <- na.omit(det_10_16)

# modelo geral sem categoria de referência
binomial_model <- glm(dengue_pattern_10_16 ~ ., data = det_10_16 , family = binomial)
```

Warning: glm.fit: probabilidades ajustadas numericamente 0 ou 1 ocorreu

```
summary(binomial_model)
```

Call:

```
glm(formula = dengue_pattern_10_16 ~ ., family = binomial, data = det_10_16)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-4.747e+03	1.995e+05	-0.024	0.981019
muni_code	-7.144e-07	4.438e-07	-1.610	0.107406
region	7.243e-01	3.910e-01	1.853	0.063945 .
tipo_regiao nao metropolitana	5.702e-03	2.569e-01	0.022	0.982295
altitude	5.589e-03	1.402e-03	3.986	6.72e-05 ***
koppenAm	3.539e-01	4.070e-01	0.870	0.384497
koppenAs	-8.680e-02	4.989e-01	-0.174	0.861870

koppenAw	-2.063e-01	4.357e-01	-0.473	0.635891	
koppenBSh	2.063e-01	5.897e-01	0.350	0.726417	
koppenCfa	3.001e-01	5.418e-01	0.554	0.579640	
koppenCfb	-1.772e+00	1.023e+00	-1.733	0.083064	.
koppenCwa	-6.722e-01	5.515e-01	-1.219	0.222902	
koppenCwb	-3.220e-01	7.763e-01	-0.415	0.678318	
pop10	6.203e-05	2.750e-06	22.560	< 2e-16	***
prop_residuo	4.857e-03	4.179e-03	1.162	0.245129	
prop_esgot	1.426e-06	2.937e-03	0.000	0.999613	
biomaCaatinga	2.243e+00	6.118e-01	3.667	0.000245	***
biomaCerrado	1.120e+00	4.572e-01	2.449	0.014311	*
biomaMata Atlantica	1.988e+00	5.332e-01	3.728	0.000193	***
biomaPampa	-2.203e+01	6.905e+02	-0.032	0.974552	
biomaPantanal	4.134e-02	1.292e+00	0.032	0.974486	
temp_med_Autumn	-7.990e-01	4.392e-01	-1.819	0.068841	.
umid_med_Autumn	-3.174e-01	9.648e-02	-3.290	0.001004	**
thr_temp_Autumn	-1.330e-02	2.051e-01	-0.065	0.948310	
thr_umid_Autumn	1.600e-01	1.986e-01	0.806	0.420489	
thr_prec_Autumn	2.926e-02	2.516e-02	1.163	0.244880	
thr_temp_umid_Autumn	-8.030e-02	1.971e-01	-0.407	0.683656	
temp_med_Spring	-1.204e+00	4.860e-01	-2.477	0.013248	*
umid_med_Spring	-8.605e-02	1.076e-01	-0.799	0.424051	
precip_tot_Spring	1.047e-03	5.945e-04	1.762	0.078112	.
thr_temp_Spring	9.422e-01	2.125e-01	4.434	9.24e-06	***
thr_umid_Spring	7.294e-01	1.864e-01	3.913	9.12e-05	***
thr_prec_Spring	1.386e-02	3.046e-02	0.455	0.649256	
thr_temp_umid_Spring	-7.164e-01	1.877e-01	-3.817	0.000135	***
temp_med_Summer	1.597e+00	4.109e-01	3.886	0.000102	***
umid_med_Summer	2.984e-01	1.076e-01	2.773	0.005548	**
precip_tot_Summer	-4.741e-04	3.534e-04	-1.342	0.179754	
thr_temp_Summer	5.124e+01	2.210e+03	0.023	0.981501	
thr_umid_Summer	5.093e+01	2.210e+03	0.023	0.981616	
thr_prec_Summer	-1.589e-02	2.604e-02	-0.610	0.541632	
thr_temp_umid_Summer	-5.097e+01	2.210e+03	-0.023	0.981600	
temp_med_Winter	1.324e+00	4.286e-01	3.089	0.002011	**
umid_med_Winter	1.260e-01	6.237e-02	2.020	0.043370	*
precip_tot_Winter	-2.274e-03	6.313e-04	-3.602	0.000316	***
thr_temp_Winter	1.902e-02	4.608e-02	0.413	0.679784	
thr_umid_Winter	1.275e-02	4.379e-02	0.291	0.771004	
thr_prec_Winter	5.712e-02	3.003e-02	1.902	0.057134	.
thr_temp_umid_Winter	-1.432e-02	4.508e-02	-0.318	0.750730	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 4027.8 on 5561 degrees of freedom
Residual deviance: 2044.8 on 5514 degrees of freedom
AIC: 2140.8

Number of Fisher Scoring iterations: 19

```
# 2. Verificação de Multicolinearidade (VIF)
# VIF só pode ser calculado em variáveis numéricas, então convertemos as categóricas para dummies
vif_values <- vif(binomial_model)

cat("\nValores de VIF:\n")
```

Valores de VIF:

```
print(vif_values)
```

	GVIF	Df	$GVIF^{1/(2*Df)}$
muni_code	6.632413e+01	1	8.143963e+00
region	6.236618e+01	1	7.897226e+00
tipo_regiao	1.339253e+00	1	1.157261e+00
altitude	3.339609e+01	1	5.778935e+00
koppen	2.178546e+03	8	1.616722e+00
pop10	1.871599e+00	1	1.368064e+00
prop_residuo	2.118873e+00	1	1.455635e+00
prop_esgot	2.589149e+00	1	1.609083e+00
bioma	1.280936e+02	5	1.624623e+00
temp_med_Autumn	3.014184e+02	1	1.736140e+01
umid_med_Autumn	1.244695e+02	1	1.115659e+01
thr_temp_Autumn	3.998373e+03	1	6.323269e+01
thr_umid_Autumn	1.897305e+03	1	4.355806e+01
thr_prec_Autumn	4.047415e+01	1	6.361929e+00
thr_temp_umid_Autumn	3.896527e+03	1	6.242216e+01
temp_med_Spring	2.654170e+02	1	1.629162e+01
umid_med_Spring	2.125916e+02	1	1.458052e+01
precip_tot_Spring	5.534431e+01	1	7.439376e+00
thr_temp_Spring	7.259001e+02	1	2.694253e+01
thr_umid_Spring	4.140441e+03	1	6.434626e+01

```
thr_prec_Spring      8.122559e+01  1  9.012524e+00
thr_temp_umid_Spring 3.934547e+03  1  6.272597e+01
temp_med_Summer      7.122342e+01  1  8.439397e+00
umid_med_Summer      1.636894e+02  1  1.279412e+01
precip_tot_Summer    3.484258e+01  1  5.902760e+00
thr_temp_Summer      2.909903e+09  1  5.394352e+04
thr_umid_Summer      2.312600e+11  1  4.808950e+05
thr_prec_Summer      8.008732e+01  1  8.949152e+00
thr_temp_umid_Summer 2.296801e+11  1  4.792495e+05
temp_med_Winter      4.935541e+02  1  2.221608e+01
umid_med_Winter      1.698262e+02  1  1.303174e+01
precip_tot_Winter    2.173688e+01  1  4.662283e+00
thr_temp_Winter      3.536773e+02  1  1.880631e+01
thr_umid_Winter      5.496260e+02  1  2.344410e+01
thr_prec_Winter      3.990092e+01  1  6.316718e+00
thr_temp_umid_Winter 5.735843e+02  1  2.394962e+01
```

3. Verificação de Outliers com Resíduos Padronizados

```
# Criar uma coluna de resíduos padronizados
det_10_16$residuos <- rstandard(binomial_model)

# Filtrar apenas os outliers (resíduos <= -3 ou >= 3)
outliers <- det_10_16 %>% filter(residuos <= -3 | residuos >= 3)

# Verificar o novo banco de dados com os outliers
print(outliers)
```

A tibble: 12 x 38

	muni_code	region	tipo_regiao	altitude	koppen	pop10	prop_residuo	prop_esgot
	<dbl>	<dbl>	<fct>	<dbl>	<fct>	<dbl>	<dbl>	<dbl>
1	1600501	1	nao metropol~	103.	Am	20509	67.0	23.9
2	2111201	2	metropolitana	11.4	As	163045	25.3	1.98
3	3109006	3	metropolitana	901.	Cwb	33973	73.8	58.6
4	3144805	3	metropolitana	1119.	Cwb	80998	63.8	53.9
5	3302858	3	metropolitana	195.	Am	168376	96.9	70.0
6	3303203	3	metropolitana	25.7	Aw	157425	99.0	92.1
7	3304144	3	metropolitana	39.3	Am	137962	94.9	85.4
8	3503901	3	metropolitana	772.	Cfb	74905	79.0	74.2
9	3510609	3	metropolitana	780.	Cfb	369584	94.4	87.7
10	3523107	3	metropolitana	761.	Cfb	321770	94.9	86.6
11	3552502	3	metropolitana	791.	Cfb	262480	73.7	69.9

```

12  4202404      4 metropolitana    245. Cfa    309011      40.0      32.0
# i 30 more variables: bioma <fct>, dengue_pattern_10_16 <fct>,
#   temp_med_Autumn <dbl>, umid_med_Autumn <dbl>, thr_temp_Autumn <dbl>,
#   thr_umid_Autumn <dbl>, thr_prec_Autumn <dbl>, thr_temp_umid_Autumn <dbl>,
#   temp_med_Spring <dbl>, umid_med_Spring <dbl>, precip_tot_Spring <dbl>,
#   thr_temp_Spring <dbl>, thr_umid_Spring <dbl>, thr_prec_Spring <dbl>,
#   thr_temp_umid_Spring <dbl>, temp_med_Summer <dbl>, umid_med_Summer <dbl>,
#   precip_tot_Summer <dbl>, thr_temp_Summer <dbl>, thr_umid_Summer <dbl>, ...

```

```


# Salvando banco
write.csv(outliers, "outliers_binomial_model_10_16.csv", row.names = FALSE)

# Removendo as observações que eram outliers ( -3 ou 3).
det_10_16<- det_10_16 %>% filter(residuos > -3 & residuos < 3)

#Visualization
ggplot(det_10_16 , aes(x = 1:nrow(det_10_16), y = residuos)) +
  geom_point() +
  geom_hline(yintercept = c(-3, 3), linetype = "dashed", color = "red") +
  labs(title = "Verificação de Outliers", x = "Índice", y = "Resíduos Padronizados")

```

Verificação de Outliers



3. Modelo de regressão logística binomial

- Interpretação:

Para cada categoria (em relação à referência “0”), o modelo estima coeficientes (Coefficients) para cada variável preditora. Esses coeficientes representam o efeito de cada variável sobre a probabilidade de estar nas categorias 1, em comparação com 0.

```
# Remover colunas pelo nome
det_10_16 <- det_10_16[, !names(det_10_16) %in% c("muni_code")]
det_10_16$region <- as.factor(det_10_16$region)
# removendo as linhas com Na
det_10_16 <- det_10_16%>%
  filter(!if_any(where(is.numeric), is.na))

# Definir a categoria de referência para todas as variáveis categóricas
det_10_16$dengue_pattern_10_16 <- relevel(det_10_16$dengue_pattern_10_16, ref = "0") # variável de referência

# Variáveis independentes
det_10_16$bioma <- relevel(det_10_16$bioma, ref = "Mata Atlantica")
det_10_16$tipo_regiao <- relevel(det_10_16$tipo_regiao, ref = "nao metropolitana")
det_10_16$koppen <- relevel(det_10_16$koppen, ref = "Aw")

# Modelo com tudo

# excluindo os resíduos
det_10_16$residuos <- NULL
binomial_model <- glm(dengue_pattern_10_16 ~ ., data = det_10_16, family = binomial)
```

Warning: glm.fit: probabilidades ajustadas numericamente 0 ou 1 ocorreu

```
summary(binomial_model)
```

Call:

```
glm(formula = dengue_pattern_10_16 ~ ., family = binomial, data = det_10_16)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-4.361e+03	2.966e+05	-0.015	0.98827
region2	-3.012e+00	5.483e-01	-5.493	3.96e-08 ***

region3	3.238e-01	4.956e-01	0.653	0.51361	
region4	6.305e-01	6.130e-01	1.028	0.30373	
region5	4.687e-01	3.800e-01	1.233	0.21748	
tipo_regiaometropolitana	-1.939e-02	2.737e-01	-0.071	0.94352	
altitude	7.205e-03	1.524e-03	4.726	2.29e-06	***
koppenAf	4.834e-01	4.638e-01	1.042	0.29725	
koppenAm	6.359e-01	3.268e-01	1.946	0.05167	.
koppenAs	5.355e-01	4.421e-01	1.211	0.22582	
koppenBSh	1.053e+00	5.543e-01	1.899	0.05754	.
koppenCfa	6.196e-01	4.022e-01	1.541	0.12339	
koppenCfb	-1.104e+00	9.795e-01	-1.127	0.25990	
koppenCwa	-4.154e-01	4.012e-01	-1.035	0.30045	
koppenCwb	3.575e-02	7.213e-01	0.050	0.96047	
pop10	7.548e-05	3.291e-06	22.937	< 2e-16	***
prop_residuo	-4.633e-04	4.454e-03	-0.104	0.91715	
prop_esgot	-5.951e-04	3.390e-03	-0.176	0.86065	
biomaAmazonia	-2.507e+00	5.765e-01	-4.349	1.37e-05	***
biomaCaatinga	6.434e-01	4.377e-01	1.470	0.14158	
biomaCerrado	-8.615e-01	2.902e-01	-2.968	0.00299	**
biomaPampa	-2.743e+01	1.093e+03	-0.025	0.97998	
biomaPantanal	-2.982e+00	1.485e+00	-2.008	0.04467	*
temp_med_Autumn	2.778e-01	5.058e-01	0.549	0.58286	
umid_med_Autumn	-3.826e-02	1.116e-01	-0.343	0.73165	
thr_temp_Autumn	-1.990e-01	2.234e-01	-0.891	0.37292	
thr_umid_Autumn	-1.256e-02	2.151e-01	-0.058	0.95344	
thr_prec_Autumn	1.279e-02	2.652e-02	0.482	0.62964	
thr_temp_umid_Autumn	6.758e-02	2.137e-01	0.316	0.75183	
temp_med_Spring	-2.089e+00	5.226e-01	-3.997	6.42e-05	***
umid_med_Spring	-1.940e-01	1.164e-01	-1.667	0.09544	.
precip_tot_Spring	1.108e-03	6.301e-04	1.758	0.07877	.
thr_temp_Spring	1.328e+00	2.334e-01	5.688	1.28e-08	***
thr_umid_Spring	1.003e+00	2.049e-01	4.896	9.79e-07	***
thr_prec_Spring	3.228e-03	3.320e-02	0.097	0.92254	
thr_temp_umid_Spring	-1.006e+00	2.061e-01	-4.881	1.06e-06	***
temp_med_Summer	1.933e+00	4.492e-01	4.302	1.69e-05	***
umid_med_Summer	2.756e-01	1.164e-01	2.367	0.01794	*
precip_tot_Summer	-9.671e-04	3.731e-04	-2.592	0.00955	**
thr_temp_Summer	4.663e+01	3.285e+03	0.014	0.98867	
thr_umid_Summer	4.626e+01	3.285e+03	0.014	0.98876	
thr_prec_Summer	5.878e-03	2.838e-02	0.207	0.83590	
thr_temp_umid_Summer	-4.629e+01	3.285e+03	-0.014	0.98876	
temp_med_Winter	1.133e+00	4.393e-01	2.580	0.00988	**
umid_med_Winter	5.170e-02	6.533e-02	0.791	0.42869	


```
# Exibir apenas o resumo final do modelo
print(summary(step_model))
```

Call:

```
glm(formula = dengue_pattern_10_16 ~ region + pop10 + thr_temp_Spring +
     bioma + koppen + temp_med_Winter + thr_temp_Autumn + temp_med_Spring +
     thr_temp_Summer + thr_temp_umid_Spring + thr_umid_Spring +
     thr_umid_Winter + altitude + temp_med_Summer + thr_umid_Summer +
     umid_med_Autumn, family = binomial, data = det_10_16)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-1.721e+02	2.163e+01	-7.955	1.78e-15	***
region2	-2.643e+00	4.461e-01	-5.926	3.11e-09	***
region3	6.130e-01	4.188e-01	1.464	0.143276	
region4	7.920e-01	5.457e-01	1.451	0.146701	
region5	7.599e-01	3.448e-01	2.204	0.027546	*
pop10	7.398e-05	3.133e-06	23.614	< 2e-16	***
thr_temp_Spring	1.347e+00	2.187e-01	6.160	7.28e-10	***
biomaAmazonia	-2.899e+00	5.426e-01	-5.344	9.10e-08	***
biomaCaatinga	4.179e-01	3.812e-01	1.096	0.272978	
biomaCerrado	-9.288e-01	2.699e-01	-3.441	0.000579	***
biomaPampa	-2.555e+01	2.852e+02	-0.090	0.928612	
biomaPantanal	-2.479e+00	1.416e+00	-1.750	0.080095	.
koppenAf	7.438e-01	3.981e-01	1.868	0.061698	.
koppenAm	6.052e-01	3.205e-01	1.888	0.059016	.
koppenAs	3.476e-01	4.056e-01	0.857	0.391487	
koppenBSh	8.788e-01	5.261e-01	1.670	0.094822	.
koppenCfa	7.928e-01	3.865e-01	2.052	0.040218	*
koppenCfb	-1.076e+00	9.595e-01	-1.122	0.261966	
koppenCwa	-4.074e-01	3.717e-01	-1.096	0.272974	
koppenCwb	-1.968e-02	6.403e-01	-0.031	0.975474	
temp_med_Winter	1.195e+00	1.433e-01	8.343	< 2e-16	***
thr_temp_Autumn	-1.221e-01	2.037e-02	-5.996	2.03e-09	***
temp_med_Spring	-1.829e+00	2.323e-01	-7.875	3.41e-15	***
thr_temp_Summer	2.826e-01	1.063e-01	2.658	0.007857	**
thr_temp_umid_Spring	-1.006e+00	1.949e-01	-5.164	2.42e-07	***
thr_umid_Spring	9.785e-01	1.928e-01	5.075	3.87e-07	***
thr_umid_Winter	1.844e-02	7.658e-03	2.408	0.016039	*
altitude	6.057e-03	1.294e-03	4.681	2.86e-06	***

```
temp_med_Summer      1.594e+00  2.956e-01   5.393 6.94e-08 ***
thr_umid_Summer      2.889e-02  1.474e-02   1.960 0.050002 .
umid_med_Autumn      9.087e-02  3.337e-02   2.723 0.006475 **
---
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

```
Null deviance: 4008.7  on 5549  degrees of freedom
Residual deviance: 1844.1  on 5519  degrees of freedom
AIC: 1906.1
```

Number of Fisher Scoring iterations: 17

5. Avaliação do ajuste do modelo

1. Pseudo R^2 (Nagelkerke, McFadden, Cox & Snell) : Mede a proporção da variância explicada pelo modelo.
 - Valores típicos: McFadden $R^2 > 0.2 \rightarrow$ Bom ajuste
 - Nagelkerke $R^2 > 0.4 \rightarrow$ Muito bom ajuste
2. Teste de Verossimilhança (Likelihood Ratio Test - LRT): Compara um modelo com e sem variáveis explicativas para ver se o modelo ajustado é significativamente melhor do que um modelo nulo. Se o p-valor for baixo (< 0.05), rejeitamos o modelo nulo, indicando que as variáveis explicativas contribuem para a predição.
3. Teste de Hosmer-Lemeshow : Avalia se as probabilidades previstas pelo modelo são bem ajustadas aos dados observados. Interpretação: p-valor $> 0.05 \rightarrow$ Indica bom ajuste
p-valor $< 0.05 \rightarrow$ Indica que o modelo pode não estar ajustando bem.
4. Curva ROC e AUC (Área Sob a Curva) : Mede a capacidade do modelo de discriminar entre as classes (0 e 1).
 - $AUC = 0.5 \rightarrow$ Modelo sem discriminação
 - AUC entre 0.7 e 0.8 $\rightarrow$ Bom modelo
 - AUC acima de 0.8 $\rightarrow$ Excelente modelo
5. Matriz de Confusão e Acurácia : Avalia o desempenho do modelo na predição correta das classes.
 - $Acurácia = (TP + TN) / (TP + TN + FP + FN)$

Resumindo:

Método	Interpretação
Pseudo R ² (Nagelkerke, McFadden)	Mede a proporção da variância explicada. Quanto maior, melhor.
LRT (Teste de Verossimilhança)	Verifica se o modelo ajustado é significativamente melhor que um modelo nulo.
Hosmer-Lemeshow	Testa se as previsões do modelo correspondem às observações reais.
Curva ROC e AUC	Mede a capacidade preditiva do modelo (valores > 0.8 indicam ótimo desempenho).
Matriz de Confusão	Avalia a acurácia da classificação do modelo.

```
# Pseudo R2
pR2(step_model)
```

fitting null model for pseudo-r2

```

          llh          llhNull          G2          McFadden          r2ML
-922.0365625 -2004.3348894  2164.5966540      0.5399788      0.3229549
      r2CU
      0.6278801
```

```
# Teste de verossimilhança (Comparação com modelo nulo)
anova(null_model, step_model, test = "Chisq")
```

Analysis of Deviance Table

Model 1: dengue_pattern_10_16 ~ region + pop10

Model 2: dengue_pattern_10_16 ~ region + pop10 + thr_temp_Spring + bioma +
koppen + temp_med_Winter + thr_temp_Autumn + temp_med_Spring +
thr_temp_Summer + thr_temp_umid_Spring + thr_umid_Spring +
thr_umid_Winter + altitude + temp_med_Summer + thr_umid_Summer +
umid_med_Autumn

```

Resid. Df Resid. Dev Df Deviance Pr(>Chi)
1      5544      2542.1
2      5519      1844.1 25    698.02 < 2.2e-16 ***
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
# Teste de Hosmer-Lemeshow
hoslem.test(det_10_16$dengue_pattern_10_16, fitted(step_model))
```

Warning in Ops.factor(1, y): '-' não faz sentido para fatores

Hosmer and Lemeshow goodness of fit (GOF) test


data: det_10_16\$dengue_pattern_10_16, fitted(step_model)
X-squared = NA, df = 8, p-value = NA

```
#Curva ROC e AUC (Área Sob a Curva)
roc_curve <- roc(det_10_16$dengue_pattern_10_16, fitted(step_model))
```

Setting levels: control = 0, case = 1

Setting direction: controls < cases

```
plot(roc_curve, col = "blue", main = "Curva ROC")
```



```
auc(roc_curve) # Calcula a AUC
```

Area under the curve: 0.9502

```
# Matriz de Confusão e Acurácia
predicoes <- ifelse(fitted(step_model) > 0.5, 1, 0)
conf_matrix <- confusionMatrix(as.factor(predicoes), as.factor(det_10_16$dengue_pattern_10_16))
print(conf_matrix)
```

Confusion Matrix and Statistics

	Reference	
Prediction	0	1
0	4826	284
1	74	366

Accuracy : 0.9355
95% CI : (0.9287, 0.9418)
No Information Rate : 0.8829
P-Value [Acc > NIR] : < 2.2e-16

Kappa : 0.6373

McNemar's Test P-Value : < 2.2e-16

Sensitivity : 0.9849
Specificity : 0.5631
Pos Pred Value : 0.9444
Neg Pred Value : 0.8318
Prevalence : 0.8829
Detection Rate : 0.8695
Detection Prevalence : 0.9207
Balanced Accuracy : 0.7740

'Positive' Class : 0